



Pytorch框架与 经典卷积神经网络与实战(二)

VGG、GoogLeNet

By~ yixuan

<https://github.com/yhe8479-ship-it>



01 VGG

02 GoogLeNet

A decorative frame consisting of a thin black rectangle with small squares at each of the four corners.


01

VGG原理与实战

VGG网络诞生背景

VGGNet是牛津大学计算机视觉组（Visual Geometry Group）和谷歌 DeepMind 一起研究出来的深度卷积神经网络，因而冠名为 VGG。


通常人们说的VGG是指VGG-16(13层卷积层+ 3层全连接层)。虽然其屈居亚军，但是由于其规律的设计、简洁可堆叠的卷积块，且在其他数据集上都有着很好的表现，从而被人们广泛使用，从这点上还是超过了GoogLeNet。VGG和之前的AlexNet相比，深度更深，参数更多(1.38亿)，效果和可移植性更好。



VGG网络结构

VGGNet有6种不同结构，我们以通常所说的VGG-16(即图D列)为例。

如图，可以发现，VGG中卷积层是通过block块形式相连的，block内的卷积层结构相同；block外，block之间通过maxpool连接。图中VGG-16中的一个vgg-block块：



其中conv3-256表示：这是一个卷积层，卷积核尺寸为 3×3 ，通道数为256。

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224×224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

vgg-block块

Table 2: Number of parameters (in millions).

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

• VGG网络结构 •

经典卷积神经网络的基本组成部分是下面的这个序列：

- (1)带填充以保持分辨率的卷积层；
- (2)非线性激活函数，如ReLU；
- (3)池化层，最大池化层。

而一个VGG块与之类似，由一系列卷积层组成，后面再加上用于空间下采样的最大池化层。

VGG特点：

1、vgg-block内的卷积层都是同结构：输入和输出的尺寸一样 $(H+2P-FH)/S + 1 = OH=H$ ，且卷积层可以堆叠复用。


实现： 统一的size为 3×3 的kernel size + stride1 + padding1

2、maxpool层将前一层(vgg-block层)的特征缩减一半：尺寸缩减的很规整，从224-112-56-28-14-7。

实现： pool size2 + stride2

3、深度较深，参数量够大：较深的网络层数可能使得训练得到的模型分类效果优秀，但是较大的参数对训练和模型保存提出了更大的资源要求。

4、较小的filter size/kernel size：这里全局的kernel size都为 3×3 ，相比以前的网络模型来说，尺寸足够小。



VGG网络参数详解

第1个vgg block层:

输入: 图像 $224 \times 224 \times 3$ 卷积核 $3 \times 3 \times 3 \times 64$ (个) 这里的3 指RGB通道数

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $224 \times 224 \times 64$ (通道数) (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

输入: $224 \times 224 \times 64$ (通道数) 卷积核 $3 \times 3 \times 64$ (个)

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $224 \times 224 \times 64$ (通道数) (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

(最大池化)

输入: $224 \times 224 \times 64$ 池化核 2×2

步幅为2 (stride = 2)

输出: $112 \times 112 \times 64$ (输出的尺寸是输入的减半, 池化后通道数不变)

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224×224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

VGG网络参数详解

第2个vgg block层:

输入: $112 \times 112 \times 64$ 卷积核 $3 \times 3 \times 128$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $112 \times 112 \times 128$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

输入: $112 \times 112 \times 128$ 卷积核 $3 \times 3 \times 128$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $112 \times 112 \times 128$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

(最大池化)

输入: $112 \times 112 \times 128$ 池化核 2×2

步幅为2 (stride = 2)

输出: $56 \times 56 \times 128$ (输出的尺寸是输入的减半, 池化后通道数不变)

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

VGG网络参数详解

第3个vgg block层:

输入: $56 \times 56 \times 128$ 卷积核 $3 \times 3 \times 256$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $56 \times 56 \times 256$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

输入: $56 \times 56 \times 256$ 卷积核 $3 \times 3 \times 256$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $56 \times 56 \times 256$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

输入: $56 \times 56 \times 256$ 卷积核 $3 \times 3 \times 256$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $56 \times 56 \times 256$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

(最大池化)

输入: $56 \times 56 \times 256$ 池化核 2×2

步幅为2 (stride = 2)

输出: $28 \times 28 \times 256$ (输出的尺寸是输入的减半, 池化后通道数不变)

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

VGG网络参数详解

第4个vgg block层:

输入: $28 \times 28 \times 256$ 卷积核 $3 \times 3 \times 512$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $28 \times 28 \times 512$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

输入: $28 \times 28 \times 512$ 卷积核 $3 \times 3 \times 512$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $28 \times 28 \times 512$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

输入: $28 \times 28 \times 512$ 卷积核 $3 \times 3 \times 512$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $28 \times 28 \times 512$ (输入和输出的尺寸一样, 经过卷积后通道数等于卷积核个数)

(最大池化)

输入: $28 \times 28 \times 512$ 池化核 2×2

步幅为2 (stride = 2)

输出: $14 \times 14 \times 512$ (输出的尺寸是输入的减半, 池化后通道数不变)

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

VGG网络参数详解

第5个vgg block层:

输入: $14 \times 14 \times 512$ **卷积核** $3 \times 3 \times 512$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $14 \times 14 \times 512$ (输入和输出的**尺寸一样**, 经过卷积后通道数等于卷积核个数)

输入: $14 \times 14 \times 512$ **卷积核** $3 \times 3 \times 512$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $14 \times 14 \times 512$ (输入和输出的**尺寸一样**, 经过卷积后通道数等于卷积核个数)

输入: $14 \times 14 \times 512$ **卷积核** $3 \times 3 \times 512$

步幅为1 (stride = 1), 填充为1 (padding=1)

输出: $14 \times 14 \times 512$ (输入和输出的**尺寸一样**, 经过卷积后通道数等于卷积核个数)

(最大池化)

输入: $14 \times 14 \times 512$ **池化核** 2×2

步幅为2 (stride = 2)

输出: $7 \times 7 \times 512$ (输出的尺寸是**输入的减半**, 池化后通道数不变)

展平flatten -> $7 \times 7 \times 512 = 25088$

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

VGG网络参数详解

第1~3层全连接层:

输入: 25088

Linear -> ReLU -> Dropout

神经元个数4096


Linear -> ReLU -> Dropout

神经元个数4096

Linear -> ReLU


分类个数1000

softmax



ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

VGG网络搭建过程




图像 -> c1 -> ReLU -> c2 -> ReLU -> Maxpooling -> c3 -> ReLU -> c4 -> ReLU -> Maxpooling -> c5 -> ReLU -> c6 -> ReLU -> c7 -> ReLU -> Maxpooling -> c8 -> ReLU -> c9 -> ReLU -> c10 -> ReLU -> Maxpooling -> c11 -> ReLU -> c12 -> ReLU -> c13 -> ReLU -> Maxpooling -> Flatten -> Linear -> ReLU -> Dropout -> Linear -> ReLU -> Dropout -> Linear -> ReLU -> soft-max

VGG总结

VGGNet总结

VGGNet通过在传统卷积神经网络模型(AlexNet)上的拓展，发现除了较为复杂的模型结构的设计(如GoogLeNet)外，深度对于提高模型准确率很重要，VGG和之前的AlexNet相比，深度更深，参数更多(1.38亿)，效果和可移植性更好，且模型设计的简洁而规律，从而被广泛使用。还有一些特点总结如下：

- 1、小尺寸的filter(3×3)不仅使参数更少，效果也并不弱于大尺寸filter如 5×5
- 2、块的使用导致网络定义的非常简洁。使用块可以有效地设计复杂的网络。
- 3、AlexNet中的局部响应归一化作用不大





02


GoogLeNet原理与 实战

GoogLeNet

网络诞生背景

在2014年的ImageNet图像识别挑战赛中，一个名叫 *GoogLeNet* 的网络架构大放异彩。

以前流行的网络使用小到 1×1 ，大到 7×7 的卷积核。本文的一个观点是，有时使用不同大小的卷积核组合是有利的。



GoogLeNet

网络结构

在 GoogLeNet 中，基本的卷积块被称为 *Inception 块* (Inception block)。这很可能得名于电影《盗梦空间》(Inception)，因为电影中的一句话“我们需要走得更深” (“We need to go deeper”)。


Inception块由四条并行路径组成。

前三条路径使用窗口大小为 1×1 、 3×3 和 5×5 的卷积层，从不同空间大小中提取信息。

中间的两条路径在输入上执行 1×1 卷积，以减少通道数，从而降低模型的复杂性。

第四条路径使用 3×3 最大池化层，然后使用 1×1 卷积层来改变通道数。

这四条路径都使用合适的填充来使输入与输出的高和宽一致，最后我们将每条线路的输出在通道维度上连结，并构成 Inception 块的输出。在 Inception 块中，通常调整的超参数是每层输出通道数。



GoogLeNet

网络结构

输入: $224 \times 224 \times 3$ 的图像。

路径1: 卷积核 $1 \times 1 \times 3 \times 64$

步幅为1 (stride=1), 填充为0 (padding=0)

特征图输出: $224 \times 224 \times 64$

路径2:

(1) 卷积核 $1 \times 1 \times 3 \times 96$


步幅为1 (stride = 1), 填充为0 (padding=0) ;

特征图输出: $224 \times 224 \times 96$

(2) 输入: $224 \times 224 \times 96$ 卷积核 $3 \times 3 \times 128$

步幅为1 (stride = 1), 填充为1 (padding=1) ;

特征图输出: $224 \times 224 \times 128$



GoogLeNet

网络结构

输入: $224 \times 224 \times 3$ 的图像。

路径3:

(1) 卷积核 $1 \times 1 \times 3 \times 16$

步幅为1 (stride=1), 填充为0 (padding=0)

特征图输出: $224 \times 224 \times 16$

(2) 输入: $224 \times 224 \times 16$ 卷积核 $5 \times 5 \times 32$

步幅为1 (stride = 1), 填充为1 (padding=1) ;

特征图输出: $224 \times 224 \times 32$

路径4:

(1) 池化核 3×3


步幅为1 (stride = 1), 填充为1 (padding=0) ;

特征图输出: $224 \times 224 \times 96$

(2) 输入: $224 \times 224 \times 96$ 卷积核 $1 \times 1 \times 32$

步幅为1 (stride = 1), 填充为1 (padding=1) ;

特征图输出: $224 \times 224 \times 32$



GoogLeNet 网络结构

通道合并:

路径1的输出为: $224 \times 224 \times 64$

路径2的输出为: $224 \times 224 \times 128$


路径3的输出为: $224 \times 224 \times 32$

路径4的输出为: $224 \times 224 \times 32$

最终通道合并为 $64 + 128 + 32 + 32 = 256$,



最终的输出为: $224 \times 224 \times 256$

那么为什么GoogLeNet这个网络如此有效呢? 首先我们考虑一下滤波器 (filter) 的组合, 它们可以用各种滤波器尺寸探索图像, 这意味着不同大小的滤波器可以有效地识别不同范围的图像细节。同时, 我们可以为不同的滤波器分配不同数量的参数。



• 1*1卷积的优点 •

有效降低了特征的维度，避免了参数爆炸。



参数量: $1*1*192*96 + 3*3*96*128 = 129024$




$3*3*192*128 = 221184$

全局平均池化层 (GAP) 优势

抑制过拟合：直接拉平做全连接层的方式依然保留了大量的空间信息，假设feature map是32个通道的10*10图像，那么拉平就得到了32*10*10的向量，如果是最后一层是对应两类标签，那么这一层就需要3200*2的权重矩阵，而GAP不同，将空间上的信息直接用均值代替，32个通道GAP之后得到的向量都是32的向量，那么最后一层只需要32*2的权重矩阵。相比之下GAP网络参数会更少，而全连接更容易在大量保留下来的空间信息上面过拟合。

GAP使特征图输入尺寸更加灵活：在前面举例里面可以看到特征图经过GAP后的大小为1*1*C，这里的C为通道的数量，因此，此刻神经网络参数不再与输入图像尺寸的大小有关，和输入特征图的通道有关，也就是输入图像的长宽可以不固定。




全局平均池化层 (GAP) 劣势

信息丢失：全局平均池化会将每个通道内的特征信息压缩成一个单一的数值。这可能会导致一些特征信息的丢失，特别是在深层网络中，重要的细节可能会被平均掉，从而降低了网络的表达能力。

特征丰富性：在一些任务中，特征之间的关系和细节对于正确的分类或预测是至关重要的。全局平均池化可能无法很好地捕捉这些特征之间的复杂关系，从而影响了模型的性能。

梯度信息：在深度学习中，梯度信息是用于权重更新的关键。在全局平均池化之后，特征图被降维为一个向量，导致梯度的传播变得更加困难。这可能会导致梯度消失或爆炸，从而影响了优化过程。

复杂任务：对于一些复杂的任务，模型需要更多的层级和特征表示，而全局平均池化可能无法提供足够的表达能力。



GoogLeNet

网络参数详解

输入: $224 \times 224 \times 3$ 三通道的图像。

第2块:

(1) 卷积层; 输入为 $224 \times 224 \times 3$, 卷积核数量为64个; 卷积核的尺寸大小为 $7 \times 7 \times 3$; 步幅为2 (stride = 2), 填充为3 (padding=3); 卷积后得到shape为 $112 \times 112 \times 64$ 的特征图输出。


(2) 最大池化层; 输入为 $112 \times 112 \times 64$, 池化核为 3×3 , 步幅为2 (stride = 2), 填充为1 (padding=1); 后得到尺寸为 $56 \times 56 \times 64$ 的池化层的特征图输出。

第3块:

(1) 卷积层; 输入为 $56 \times 56 \times 64$, 卷积核数量为64个; 卷积核的尺寸大小为 $1 \times 1 \times 64$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $56 \times 56 \times 64$ 的特征图输出。

(2) 卷积层; 输入为 $56 \times 56 \times 64$, 卷积核数量为192个; 卷积核的尺寸大小为 $3 \times 3 \times 64$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $56 \times 56 \times 192$ 的特征图输出。

(3) 最大池化层; 输入为 $56 \times 56 \times 192$, 池化核为 3×3 , 步幅为2 (stride = 2), 填充为1 (padding=1); 后得到尺寸为 $28 \times 28 \times 192$ 的池化层的特征图输出。



GoogLeNet

网络参数详解

第1个Inception块:

输入为 $28 \times 28 \times 192$ 的特征图。

路径1:

(1) 输入为 $28 \times 28 \times 192$, 卷积核数量为64个; 卷积核的尺寸大小为 $1 \times 1 \times 192$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $28 \times 28 \times 64$ 的特征图输出。

路径2:

(1) 输入为 $28 \times 28 \times 192$, 卷积核数量为96个; 卷积核的尺寸大小为 $1 \times 1 \times 192$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $28 \times 28 \times 96$ 的特征图输出。

(2) 输入为 $28 \times 28 \times 96$, 卷积核数量为128个; 卷积核的尺寸大小为 $3 \times 3 \times 96$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $28 \times 28 \times 128$ 的特征图输出。

路径3:


(1) 输入为 $28 \times 28 \times 192$, 卷积核数量为16个; 卷积核的尺寸大小为 $1 \times 1 \times 192$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $28 \times 28 \times 16$ 的特征图输出。

(2) 输入为 $28 \times 28 \times 16$, 卷积核数量为32个; 卷积核的尺寸大小为 $5 \times 5 \times 16$; 步幅为1 (stride = 1), 填充为2 (padding=2); 卷积后得到shape为 $28 \times 28 \times 32$ 的特征图输出。

路径4:

(1) 输入为 $28 \times 28 \times 192$, 池化核的尺寸大小为 3×3 ; 步幅为1 (stride = 1), 填充为1 (padding=1); 池化后得到shape为 $28 \times 28 \times 192$ 的特征图输出。

(2) 输入为 $28 \times 28 \times 192$, 卷积核数量为32个; 卷积核的尺寸大小为 $1 \times 1 \times 3$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $28 \times 28 \times 32$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:


路径1的到输出为: $28 \times 28 \times 64$

路径2的到输出为: $28 \times 28 \times 128$

路径3的到输出为: $28 \times 28 \times 32$

路径4的到输出为: $28 \times 28 \times 32$

最终通道合并为 $64 + 128 + 32 + 32 = 256$, 最终的输出为:
 $28 \times 28 \times 256$ 。



GoogLeNet

网络参数详解

第2个Inception块:

输入为 $28 \times 28 \times 256$ 的特征图。

路径1:

(1) 输入为 $28 \times 28 \times 256$ ，卷积核数量为128个；卷积核的尺寸大小为 $1 \times 1 \times 256$ ；步幅为1 (stride = 1)，填充为0 (padding=0)；卷积后得到shape为 $28 \times 28 \times 128$ 的特征图输出。

路径2:

(1) 输入为 $28 \times 28 \times 256$ ，卷积核数量为128个；卷积核的尺寸大小为 $1 \times 1 \times 256$ ；步幅为1 (stride = 1)，填充为0 (padding=0)；卷积后得到shape为 $28 \times 28 \times 128$ 的特征图输出。

(2) 输入为 $28 \times 28 \times 256$ ，卷积核数量为192个；卷积核的尺寸大小为 $3 \times 3 \times 256$ ；步幅为1 (stride = 1)，填充为1 (padding=1)；卷积后得到shape为 $28 \times 28 \times 192$ 的特征图输出。

路径3:


(1) 输入为 $28 \times 28 \times 256$ ，卷积核数量为32个；卷积核的尺寸大小为 $1 \times 1 \times 256$ ；步幅为1 (stride = 1)，填充为0 (padding=0)；卷积后得到shape为 $28 \times 28 \times 32$ 的特征图输出。

(2) 输入为 $28 \times 28 \times 32$ ，卷积核数量为96个；卷积核的尺寸大小为 $5 \times 5 \times 32$ ；步幅为1 (stride = 1)，填充为2 (padding=2)；卷积后得到shape为 $28 \times 28 \times 96$ 的特征图输出。

路径4:

(1) 输入为 $28 \times 28 \times 256$ ，池化核的尺寸大小为 3×3 ；步幅为1 (stride = 1)，填充为1 (padding=1)；池化后得到shape为 $28 \times 28 \times 256$ 的特征图输出。

(2) 输入为 $28 \times 28 \times 256$ ，卷积核数量为64个；卷积核的尺寸大小为 $1 \times 1 \times 256$ ；步幅为1 (stride = 1)，填充为0 (padding=0)；卷积后得到shape为 $28 \times 28 \times 64$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:

路径1的到输出为: $28 \times 28 \times 128$

路径2的到输出为: $28 \times 28 \times 192$


路径3的到输出为: $28 \times 28 \times 96$

路径4的到输出为: $28 \times 28 \times 64$

最终通道合并为 $128+192+96+64=480$, 最终的输出为:
 $28 \times 28 \times 480$ 。

最大池化模块:

输入为 $28 \times 28 \times 480$ 。池化核的尺寸大小为 3×3 ; 步幅为2 (stride = 2) , 填充为1 (padding=1) ; 池化后得到shape为 $14 \times 14 \times 480$ 的特征图输出。



GoogLeNet

网络参数详解

第3个Inception块:

输入为 $14 \times 14 \times 480$ 的特征图。

路径1:

(1) 输入为 $14 \times 14 \times 480$, 卷积核数量为192个; 卷积核的尺寸大小为 $1 \times 1 \times 480$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 192$ 的特征图输出。

路径2:

(1) 输入为 $14 \times 14 \times 480$, 卷积核数量为96个; 卷积核的尺寸大小为 $1 \times 1 \times 480$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 96$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 96$, 卷积核数量为208个; 卷积核的尺寸大小为 $3 \times 3 \times 96$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $14 \times 14 \times 208$ 的特征图输出。

路径3:


(1) 输入为 $14 \times 14 \times 480$, 卷积核数量为16个; 卷积核的尺寸大小为 $1 \times 1 \times 480$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 16$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 16$, 卷积核数量为48个; 卷积核的尺寸大小为 $5 \times 5 \times 16$; 步幅为1 (stride = 1), 填充为2 (padding=2); 卷积后得到shape为 $14 \times 14 \times 48$ 的特征图输出。

路径4:

(1) 输入为 $14 \times 14 \times 480$, 池化核的尺寸大小为 3×3 ; 步幅为1 (stride = 1), 填充为1 (padding=1); 池化后得到shape为 $14 \times 14 \times 480$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 480$, 卷积核数量为64个; 卷积核的尺寸大小为 $1 \times 1 \times 3$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:


路径1的到输出为: $14 \times 14 \times 192$

路径2的到输出为: $14 \times 14 \times 208$

路径3的到输出为: $14 \times 14 \times 48$

路径4的到输出为: $14 \times 14 \times 64$

最终通道合并为 $192 + 208 + 48 + 64 = 512$, 最终的输出为:
 $14 \times 14 \times 512$ 。



GoogLeNet

网络参数详解

第4个Inception块:

输入为 $14 \times 14 \times 512$ 的特征图。

路径1:

(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为160个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 160$ 的特征图输出。

路径2:

(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为112个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 112$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 112$, 卷积核数量为224个; 卷积核的尺寸大小为 $3 \times 3 \times 112$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $14 \times 14 \times 224$ 的特征图输出。

路径3:


(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为24个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 24$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 24$, 卷积核数量为64个; 卷积核的尺寸大小为 $5 \times 5 \times 24$; 步幅为1 (stride = 1), 填充为2 (padding=2); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。

路径4:

(1) 输入为 $14 \times 14 \times 512$, 池化核的尺寸大小为 3×3 ; 步幅为1 (stride = 1), 填充为1 (padding=1); 池化后得到shape为 $14 \times 14 \times 512$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 512$, 卷积核数量为64个; 卷积核的尺寸大小为 $1 \times 1 \times 3$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:


路径1的到输出为: $14 \times 14 \times 160$

路径2的到输出为: $14 \times 14 \times 224$

路径3的到输出为: $14 \times 14 \times 64$

路径4的到输出为: $14 \times 14 \times 64$

最终通道合并为 $160 + 224 + 64 + 64 = 512$, 最终的输出为:
 $14 \times 14 \times 512$ 。



GoogLeNet

网络参数详解

第5个Inception块:

输入为 $14 \times 14 \times 512$ 的特征图。

路径1:

(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为128个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $14 \times 14 \times 128$ 的特征图输出。

路径2:

(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为128个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $14 \times 14 \times 128$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 128$, 卷积核数量为256个; 卷积核的尺寸大小为 $3 \times 3 \times 128$; 步幅为1 ($\text{stride} = 1$), 填充为1 ($\text{padding}=1$); 卷积后得到shape为 $14 \times 14 \times 256$ 的特征图输出。

路径3:


(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为24个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $14 \times 14 \times 24$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 24$, 卷积核数量为64个; 卷积核的尺寸大小为 $5 \times 5 \times 24$; 步幅为1 ($\text{stride} = 1$), 填充为2 ($\text{padding}=2$); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。

路径4:

(1) 输入为 $14 \times 14 \times 512$, 池化核的尺寸大小为 3×3 ; 步幅为1 ($\text{stride} = 1$), 填充为1 ($\text{padding}=1$); 池化后得到shape为 $14 \times 14 \times 512$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 512$, 卷积核数量为64个; 卷积核的尺寸大小为 $1 \times 1 \times 3$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:


路径1的到输出为: $14 \times 14 \times 128$

路径2的到输出为: $14 \times 14 \times 256$

路径3的到输出为: $14 \times 14 \times 64$

路径4的到输出为: $14 \times 14 \times 64$

最终通道合并为 $128 + 256 + 64 + 64 = 512$, 最终的输出为:
 $14 \times 14 \times 512$ 。



GoogLeNet

网络参数详解

第6个Inception块:

输入为 $14 \times 14 \times 512$ 的特征图。

路径1:

(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为112个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 112$ 的特征图输出。

路径2:

(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为128个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 128$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 128$, 卷积核数量为288个; 卷积核的尺寸大小为 $3 \times 3 \times 128$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $14 \times 14 \times 288$ 的特征图输出。

路径3:


(1) 输入为 $14 \times 14 \times 512$, 卷积核数量为32个; 卷积核的尺寸大小为 $1 \times 1 \times 512$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 32$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 32$, 卷积核数量为64个; 卷积核的尺寸大小为 $5 \times 5 \times 32$; 步幅为1 (stride = 1), 填充为2 (padding=2); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。

路径4:

(1) 输入为 $14 \times 14 \times 512$, 池化核的尺寸大小为 3×3 ; 步幅为1 (stride = 1), 填充为1 (padding=1); 池化后得到shape为 $14 \times 14 \times 512$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 512$, 卷积核数量为64个; 卷积核的尺寸大小为 $1 \times 1 \times 3$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 64$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:


路径1的到输出为: $14 \times 14 \times 112$

路径2的到输出为: $14 \times 14 \times 288$

路径3的到输出为: $14 \times 14 \times 64$

路径4的到输出为: $14 \times 14 \times 64$

最终通道合并为 $112 + 288 + 64 + 64 = 528$, 最终的输出为:
 $14 \times 14 \times 528$ 。



GoogLeNet

网络参数详解

第7个Inception块:

输入为 $14 \times 14 \times 528$ 的特征图。

路径1:

(1) 输入为 $14 \times 14 \times 528$, 卷积核数量为256个; 卷积核的尺寸大小为 $1 \times 1 \times 528$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 256$ 的特征图输出。

路径2:

(1) 输入为 $14 \times 14 \times 528$, 卷积核数量为160个; 卷积核的尺寸大小为 $1 \times 1 \times 528$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 160$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 160$, 卷积核数量为320个; 卷积核的尺寸大小为 $3 \times 3 \times 160$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $14 \times 14 \times 320$ 的特征图输出。

路径3:


(1) 输入为 $14 \times 14 \times 528$, 卷积核数量为32个; 卷积核的尺寸大小为 $1 \times 1 \times 528$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 32$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 32$, 卷积核数量为128个; 卷积核的尺寸大小为 $5 \times 5 \times 32$; 步幅为1 (stride = 1), 填充为2 (padding=2); 卷积后得到shape为 $14 \times 14 \times 128$ 的特征图输出。

路径4:

(1) 输入为 $14 \times 14 \times 528$, 池化核的尺寸大小为 3×3 ; 步幅为1 (stride = 1), 填充为1 (padding=1); 池化后得到shape为 $14 \times 14 \times 528$ 的特征图输出。

(2) 输入为 $14 \times 14 \times 528$, 卷积核数量为128个; 卷积核的尺寸大小为 $1 \times 1 \times 528$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $14 \times 14 \times 128$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:

路径1的到输出为: $14 \times 14 \times 256$

路径2的到输出为: $14 \times 14 \times 320$


路径3的到输出为: $14 \times 14 \times 128$

路径4的到输出为: $14 \times 14 \times 128$

最终通道合并为 $256 + 320 + 128 + 128 = 832$, 最终的输出为:
 $14 \times 14 \times 832$ 。

最大池化模块:

输入为 $14 \times 14 \times 832$ 。池化核的尺寸大小为 3×3 ; 步幅为2 (stride = 2), 填充为1 (padding=1); 池化后得到shape为 $7 \times 7 \times 832$ 的特征图输出。



GoogLeNet

网络参数详解

第8个Inception块:

输入为 $7 \times 7 \times 832$ 的特征图。

路径1:

(1) 输入为 $7 \times 7 \times 832$, 卷积核数量为256个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $7 \times 7 \times 256$ 的特征图输出。

路径2:

(1) 输入为 $7 \times 7 \times 832$, 卷积核数量为160个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $7 \times 7 \times 160$ 的特征图输出。

(2) 输入为 $7 \times 7 \times 160$, 卷积核数量为320个; 卷积核的尺寸大小为 $3 \times 3 \times 160$; 步幅为1 ($\text{stride} = 1$), 填充为1 ($\text{padding}=1$); 卷积后得到shape为 $7 \times 7 \times 320$ 的特征图输出。

路径3:


(1) 输入为 $7 \times 7 \times 832$, 卷积核数量为32个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $7 \times 7 \times 32$ 的特征图输出。

(2) 输入为 $7 \times 7 \times 32$, 卷积核数量为128个; 卷积核的尺寸大小为 $5 \times 5 \times 32$; 步幅为1 ($\text{stride} = 1$), 填充为2 ($\text{padding}=2$); 卷积后得到shape为 $7 \times 7 \times 128$ 的特征图输出。

路径4:

(1) 输入为 $7 \times 7 \times 832$, 池化核的尺寸大小为 3×3 ; 步幅为1 ($\text{stride} = 1$), 填充为1 ($\text{padding}=1$); 池化后得到shape为 $7 \times 7 \times 832$ 的特征图输出。

(2) 输入为 $7 \times 7 \times 832$, 卷积核数量为128个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 ($\text{stride} = 1$), 填充为0 ($\text{padding}=0$); 卷积后得到shape为 $7 \times 7 \times 128$ 的特征图输出。



GoogLeNet

网络参数详解

通道合并:


路径1的到输出为: $7 \times 7 \times 256$

路径2的到输出为: $7 \times 7 \times 320$

路径3的到输出为: $7 \times 7 \times 128$

路径4的到输出为: $7 \times 7 \times 128$

最终通道合并为 $256 + 320 + 128 + 128 = 832$, 最终的输出为:
 $7 \times 7 \times 832$ 。



GoogLeNet

网络结构

第9个Inception块:

输入为 $7 \times 7 \times 832$ 的特征图。

路径1:

(1) 输入为 $7 \times 7 \times 832$, 卷积核数量为384个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $7 \times 7 \times 384$ 的特征图输出。

路径2:

(1) 输入为 $7 \times 7 \times 832$, 卷积核数量为192个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $7 \times 7 \times 192$ 的特征图输出。

(2) 输入为 $7 \times 7 \times 192$, 卷积核数量为384个; 卷积核的尺寸大小为 $3 \times 3 \times 192$; 步幅为1 (stride = 1), 填充为1 (padding=1); 卷积后得到shape为 $7 \times 7 \times 384$ 的特征图输出。

路径3:


(1) 输入为 $7 \times 7 \times 832$, 卷积核数量为48个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $7 \times 7 \times 48$ 的特征图输出。

(2) 输入为 $7 \times 7 \times 48$, 卷积核数量为128个; 卷积核的尺寸大小为 $5 \times 5 \times 48$; 步幅为1 (stride = 1), 填充为2 (padding=2); 卷积后得到shape为 $7 \times 7 \times 128$ 的特征图输出。

路径4:

(1) 输入为 $7 \times 7 \times 832$, 池化核的尺寸大小为 3×3 ; 步幅为1 (stride = 1), 填充为1 (padding=1); 池化后得到shape为 $7 \times 7 \times 832$ 的特征图输出。

(2) 输入为 $7 \times 7 \times 832$, 卷积核数量为128个; 卷积核的尺寸大小为 $1 \times 1 \times 832$; 步幅为1 (stride = 1), 填充为0 (padding=0); 卷积后得到shape为 $7 \times 7 \times 128$ 的特征图输出。



GoogLeNet

网络结构

通道合并:


路径1的到输出为: $7 \times 7 \times 384$

路径2的到输出为: $7 \times 7 \times 384$

路径3的到输出为: $7 \times 7 \times 128$

路径4的到输出为: $7 \times 7 \times 128$

最终通道合并为 $384 + 384 + 128 + 128 = 1024$, 最终的输出为:
 $7 \times 7 \times 1024$ 。



GoogLeNet 网络结构

全局平均池化模块:


输入为 $7 \times 7 \times 1024$ 。池化后得到shape为 $1 \times 1 \times 1024$ 的特征图输出。

Flatten层:

输入为 $1 \times 1 \times 1024$ ，输出为 1×1024 。

线性全连接层:

输入为 1×1024 。线性全连接层神经元个数分别为1000。最后一层全连接层用softmax输出1000个分类。





GoogLeNet 总结

GoogLeNet总结

通过创新性的**Inception模块**和较为复杂的网络设计，使得作者团队上力压VGGNet夺冠。而GoogLeNet作为Inception模块设计的代表，有很多值得学习的地方：



- 通过并行的filter将输入特征提取并在通道维上进行串联合并，构成下一层的输入，再将Inception块层层叠加。通过这种方式引入了稀疏型、模拟了卷积视觉网络的最佳拓扑结构。同时也让网络具备了自动选择的能力，而不是人为地设置卷积或池化，或决定卷积核的尺寸（不同分支后面都有可学习参数，比如 1×1 、 3×3 、 5×5 卷积核的权重。）
- 为了降低整体参数量，在Inception块中添加了 **1×1 卷积**，有效降低了特征的维度，避免了参数爆炸。



(b) Inception module with dimensionality reduction

GoogLeNet

实战



测试样本总数：10000
预测正确样本数：9209
测试集准确率为：0.9209



THANK YOU~~